Український Католицький Університет

КУРС «ШТУЧНИЙ ІНТЕЛЕКТ» · УКУ

# MMCultureQA SemEval-2027

Мідтерм · 26.10.2026

Команда: Марина Огінська,
Ярина Печененко

# Відповісти на питання до зображення, спираючись на місцеву культуру; питання ставлять текстом або голосом

SemEval-2027 · MMCultureQA | English track · MENA | github.com/mohinska/mmculture-qa

## ДВІ ЗАДАЧІ

Task 1 · Spoken VQA: зображення + усне питання (Ярина)

Task 2 · Textual VQA: зображення + текстове питання (Марина)

Output: коротка відповідь вільним текстом

## ДАНІ · QCRI/MMCQA-SemEval27

dev 1 000 · train 10 000 · devtest 1 000 із прихованими відповідями

Аудіо в train і dev синтетичне (TTS); у test будуть живі записи

В англійських даних немає міток країни чи категорії

## МЕТРИКА · ОФІЦІЙНИЙ SCORER

**Ранжування:** BERTScore-F1, jhu-clsp/mmBERT-base, layer 17

**Також у звіті:** BERTScore-P і R, BLEU, ROUGE-L, Coverage (частка непорожніх відповідей)

## EDA · DEV 1 000

Gold-відповіді є повними реченнями: медіана 24 слова, 76% складаються з одного речення

Довжина залежить від типу питання: на significance / meaning медіана 30 слів, на «What is / which» 20

Відповіді переказують питання (43% його змістовних слів) і часто містять hedging (25%: «likely», «may»)

# Одна VLM в обох задачах

| | | | | |
|---|---|---|---|---|
| **TASK 2 · ТЕКСТ** | зображення + текстове питання | Qwen3-VL, prompt gold_style | коротка відповідь | офіційний scorer |
| **TASK 1 · CASCADE** | зображення + усне питання | Whisper large-v3-turbo → транскрипт | Qwen3-VL і prompt | офіційний scorer + наш WER |
| **TASK 1 · END-TO-END** | зображення + усне питання | Qwen2.5-Omni-3B, 4-bit (офіційний baseline) | коротка відповідь | офіційний scorer |

### ЧОМУ CASCADE ДЛЯ TASK 1

Вищий бал: 0.7912 проти 0.7382 в офіційного end-to-end baseline

Кожне покращення Task 2 переходить автоматично

Найкраща модель для кожного кроку, обрана окремо

Помилки простежувані: транскрипт можна прочитати

### ЧОМУ ЦІ МОДЕЛІ

Qwen3-VL 4B і 8B: відкриті ваги; Gemma 3 4B слабша: 0.76 проти 0.79 у Qwen3-VL-4B з gold_style_v1

Whisper large-v3-turbo: найнижчий WER

Qwen2.5-Omni-3B: official reference baseline

# Prompt дає +0.06 будь-якій моделі; голос майже нічого не коштує

**TASK 2 · ТЕКСТОВЕ ПИТАННЯ · BERTScore-F1**

| Модель | prompt plain | prompt gold_style_v1 |
|---|---|---|
| **Qwen3-VL-4B** | 0.7322 | **0.7915** |
| **Qwen3-VL-8B** | 0.7252 | 0.7880 |
| **Gemma 3 4B** | 0.7070 | 0.7690 |

**TASK 1 · УСНЕ ПИТАННЯ · BERTScore-F1**

| Система | Усне питання | Те саме текстом |
|---|---|---|
| **Whisper turbo → Qwen3-VL-4B** | **0.7912** | 0.7914 |
| **Whisper turbo → Qwen3-VL-8B** | 0.7856 | 0.7881 |
| **Qwen2.5-Omni-3B, офіційний baseline** | 0.7382 [1] | |

**Cascade = відповідь на текст:** −0.0002 (4B), −0.0025 (8B).
Офіційний end-to-end baseline на 0.05 нижчий.

dev, 200 тих самих питань (seed 0), офіційний scorer. «Те саме текстом»: та сама модель і prompt, прогнано в тій самій сесії. [1] 163 з 200 відповідей Omni продовжуються вигаданими репліками «Human:»; обрізані до першого рядка дають 0.7547 (наша обробка).

# Task 1 ламають втрачені назви, Task 2 плутає сам об'єкт

**TASK 1 · УСНЕ ПИТАННЯ · CASCADE**

## −0.02

зміна балу на питаннях, де Whisper загубив назву (3 з 200).

Загалом ASR майже не шкодить: WER 0.92%, а Spearman(WER, зміна балу) = −0.03.

Важить не кількість помилок, а яке слово загубилося.

**ПРИКЛАД · ЗМІНА БАЛУ −0.044**

**Питання:** What architectural features can be observed in this alleyway leading to the mosque?

**Whisper транскрипт:** ...leading to the moth?

**Відповідь з тексту:** The alleyway leads to the mosque, featuring whitewashed walls, arched doorways...

**Відповідь з аудіо:** The alleyway leads to the Ksar of Aït Benhaddou...

**TASK 2 · ТЕКСТОВЕ ПИТАННЯ**

## 9 з 20

найгірших відповідей Qwen3-VL-4B називають не той об'єкт: іншу пам'ятку, рослину чи країну.

Ще 9 правильні по суті, але з іншими деталями або вгаданим місцем (Marrakech, Wadi Rum); 2 надто загальні.

**ПРИКЛАД · F1 0.708**

**Питання:** What ancient civilization is most closely associated with the pyramids shown in this desert landscape...?

**Gold:** ...the Kingdom of Kush, specifically the Nubian civilization in present-day Sudan.

**Модель:** The pyramids shown are likely from ancient Egypt, built as tombs for pharaohs...

dev, n = 200, BERTScore-F1. Task 1: Whisper turbo → Qwen3-VL-4B, зміна балу = F1 з аудіо − F1 з тексту. Task 2: Qwen3-VL-4B, gold_style_v1, ручні мітки 20 найгірших.

# Baseline і prompting

## РОЗПОДІЛ РОБОТИ

**Ярина:** speech pipeline. WER, порівняння розмірів Whisper, cascade, speech vs text на 4B і 8B, аналіз помилок, аудит офіційного baseline

**Марина:** завантаження даних і EDA, спільний код, інтеграція офіційного scorer, інструмент для сабмітів, VLM baseline-и і gold-style prompt, аналіз помилок Task 2

## ЩО НЕ ВИЙШЛО

**Брудні дані:** немає міток країни й категорії, а серед фото трапляються не з MENA. Аналізуємо за назвами місць, але їх має лише 33% dev-прикладів

**Назви на слух:** Whisper погано читає власні назви й написи з фото: ESSAOUIRA → «Esawaira», The Pointe → «the point», Royal Force → «Royal For is», mosque → «moth»

**Синтетичне аудіо:** train і dev озвучені TTS, а test буде справжнім записом, тож низький WER на dev може не втриматися

6 · НАСТУПНІ КРОКИ

# Next

### 1 · NAMES & CONTEXT

Я: prompt для Whisper з назвами місць і страв MENA; перезапуск large-v3; cascade на всіх 1 000; перший сабміт на devtest

M: few-shot з train; культурний контекст (передбачення країни або RAG); post-processing відповідей

### 2 · REAL AUDIO + LoRA

Я: власні записи голосом; аугментація шумом, швидкістю, reverb; LLM-корекція транскриптів із зображенням

M: LoRA fine-tuning на train, Task 1 отримає його автоматично; zero-shot vs few-shot vs fine-tune

### 3 · FREEZE & DRAFT

Фінальна конфігурація для кожної задачі

Inference-ноутбуки у форматі CodaBench

Чернетка статті

### 4 · TEST SUBMISSION

Сабміт 2–3 найкращих конфігурацій

System paper у лютому

### ДИЗАЙН ЕКСПЕРИМЕНТІВ

1. Kaggle (T4 x2): download_data.py → run_vlm.py / run_cascade.py на тих самих 200 dev id
2. Одна зміна за прогін: prompt, ASR-модель, few-shot або LoRA-адаптер з train
3. Качаємо preds/*.jsonl, скоримо локально офіційним scorer → results/*.json
4. Найкраще: --n 0 на всі 1 000 dev, make_submission.py → devtest leaderboard

### PLAN B · IF CASCADE STALLS

End-to-end Qwen2.5-Omni з нашим prompt і без вигаданих реплік

Або комбінація: брати end-to-end відповідь, коли Whisper не впевнений

### IF IT ALL WORKS

Фінальні конфігурації і сабміт на тест у січні

System description paper для SemEval-2027