Український Католицький Університет

Курс «Штучний інтелект» · Семестровий проєкт · 2026

SemEval-2027 shared task MMCultureQA, Textual Visual QA

Команда:

Огінська Марина

Печененко Ярина

Ментори:

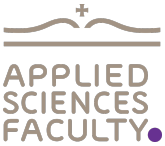
Марта Сумик

Олександр Косован

Пропозиція проєкту, подана в межах курсу «Штучний інтелект»

Факультет прикладних наук





2026-09-21

1. Проблема та мотивація

Сучасні мультимодальні моделі (VLM) здебільшого навчаються на даних із західного сегмента інтернету, що утворює проблему ”cultural bias”. Стикаючись із візуальним контентом інших регіонів, моделі часто не здатні правильно інтерпретувати місцеві традиції чи побут, генеруючи так звані ”культурні галюцинації”. Ціль проєкту — розв’язати цю проблему в межах змагання MMCultureQA (Task 2), де розробляється система для генерації відкритих текстових відповідей на текстові запитання до зображень із глибоким розумінням локального контексту. Цінність проєкту полягає в демократизації штучного інтелекту та забезпеченні його інклюзивності для не-західних культур.

2. Огляд джерел та наявних рішень

Серед актуальних для нашого проєкту підходів у сфері культурно-адаптованого ШІ, фундаментальною є архітектура EverydayMMQA [1] — фреймворк, який використовує колаборацію мовних моделей та місцевих експертів для генерації локалізованих мультимодальних даних. Також важливим є досвід проєкту CultureLLM [2], який доводить можливість ефективного донавчання за допомогою семантичної аугментації невеликого обсягу базових даних без значних обчислювальних витрат, та підхід CulturalPangea [3], де для збагачення культурного контексту моделей та уникнення фактологічних помилок використовуються зовнішні графи знань (наприклад, Wikidata). Окремий напрям складають методи retrieval-augmented generation, які додають ”зовнішні знання” (outside knowledge) безпосередньо в контекст моделі під час інференсу, без донавчання ваг: RA-VQA [4] показує, що для запитань, які вимагають знань поза межами самого зображення (що є типовим випадком для культурно-специфічних питань про їжу, звичаї чи предмети), релевантний пошук і подача текстових фрагментів у контекст суттєво покращують якість відповіді. Цей підхід ми розглядаємо як третій кандидат-метод поряд із prompt engineering та донавчанням (див. розділ 4).

3. Дані

Ми використовуємо дані офіційного shared task MMCultureQA (SemEval 2027), зокрема підзавдання Task 2 — Textual Visual QA, опубліковані QCRI на Hugging Face (`QCRI/MMCQA-SemEval27`). Датасет побудований на основі ширшого мультимодального корпусу OASIS/EverydayMMQA [1] і містить пари зображення–питання–відповідь, орієнтовані на культурно-специфічні знання (їжа, звичаї, місця, предмети) для англійської та літературної арабської мов.

Попередній огляд даних (EDA). На даний момент опубліковано тільки sample-реліз розміром 60 записів, розподілених по 15 між чотирма підмножинами: `qa_en`, `qa_msa` (текстові питання, релевантні нашому Task 2) та `sqa_en`, `sqa_msa` (усні питання з аудіозаписом). Для нашого завдання безпосередньо доступно по 15 прикладів англійською та арабською мовами, з поділом 9 train / 6 dev у кожній підмножині; тестового набору в семплі немає. Кожен запис містить поля `id`, `image` (JPEG), `question`, `answer`, `country`, `category`, `subcategory`. Дані охоплюють 4 країни (Єгипет, ОАЕ, Сирія, Марокко) і згруповані у 6 тематичних категорій та 9 підкатегорій, що дозволяє вже на цьому етапі оцінити розподіл за темами і потенційний дисбаланс класів, хоча остаточні висновки можливі лише після публікації повного релізу. Повні тренувальний та тестовий набори організатори опублікують пізніше за офіційним графіком змагання. Дані розповсюджуються під ліцензією CC-BY-NC-4.0.

4. Підхід і методи

Зважаючи на ресурсні обмеження та фокус виключно на текстово-візуальному треку (Task 2), плануємо порівняти щонайменше три підходи на базі відкритих мультимодальних моделей (VLM), таких як LLaVA-1.5 7B або Qwen-VL [5]:

1. **Baseline** — обрана VLM у режимі zero-shot: зображення та текстове питання подаються в модель

без додаткової обробки.
2. **Prompt engineering** — та сама модель, якій задається роль культурного експерта та надаються цільові інструкції/приклади (few-shot), без зміни ваг моделі.
3. **Донавчання (PEFT QLoRA)** — якщо якість prompt engineering виявиться недостатньою, адаптуємо VLM до тренувального датасету методом параметрично-ефективного донавчання з 4-бітною квантизацією на споживчих відеокартах.

Додатково як альтернативу або доповнення до донавчання розглянемо retrieval-augmented підхід за зразком RA-VQA [4]: пошук релевантних текстових фрагментів (наприклад, з Wikipedia/Wikidata) і подача їх у контекст моделі під час інференсу, без зміни ваг. Це дозволить перевірити, чи достатньо додавання зовнішніх культурних знань у контекст без витратного донавчання. Остаточний вибір між методом 3 та retrieval-augmented варіантом (або їх обома) залежатиме від наявних обчислювальних ресурсів і проміжних результатів. У фінальному звіті плануємо порівняти всі реалізовані методи між собою та з baseline за метриками, описаними в розділі 5.

5. Оцінювання результатів

Оскільки завдання вимагає генерації відкритих текстових відповідей, класичної метрики точності (accuracy) недостатньо [6]. Метрики, які ми використовуємо, відповідають офіційному опису оцінювання Task 2 самого shared task (а не є нашим самостійним вибором): організатори визначають **BERTScore F1** як єдину метрику для офіційного рейтингування систем (оцінює семантичну близькість згенерованої відповіді до еталонної, тож коректні за змістом, але інакше сформульовані відповіді також отримують високий бал), а **BLEU** та **ROUGE-L** публікуються організаторами як допоміжні лексичні метрики для контексту й перевірки збігу специфічних сутностей (назв страв, традиційного одягу), але не впливають на офіційний рейтинг [6]. Офіційний скрипт оцінювання буде опубліковано разом із даними, що дозволить відтворювати рейтингову метрику локально до подання результатів. Як baseline розглядатимуться результати обраної VLM (наприклад, LLaVA-1.5) у режимі zero-shot на текстових запитаннях. Основна мета — перевершити цей baseline за метрикою BERTScore F1, і додатково порівняти всі розглянуті методи за повним набором метрик (BERTScore F1, BLEU, ROUGE-L).

6. План і ризики

Проєкт розрахований на 14 тижнів. План включає: опрацювання основ роботи з мультимодальними моделями та екосистемою Hugging Face (тижні 1-3), розвідувальний аналіз текстових та візуальних даних (тижні 4-5), реалізацію baseline-моделі для текстових запитань (тижні 6-8), проведення експериментів з інженерією підказок, retrieval-augmented доповненням контексту та можливим QLoRA-донавчанням (тижні 9-12), обчислення фінальних метрик, порівняння всіх методів і написання звіту (тижні 13-14). Головними ризиками є обмежений досвід нашої команди в машинному навчанні (що буде мінімізовано використанням високорівневих бібліотек `transformers`) та нестача відеопам'яті (OOM errors), що долатиметься завдяки 4-бітній квантизації моделей та малим розмірам батчу під час навчання.

7. Contribution statement

- **Огінська Марина** — робота з даними, препроцесинг, EDA, інфраструктура проєкту
- **Печененко Ярина** — моделювання, інженерія підказок, евалюація, написання звіту

Список джерел

[1] Firoj Alam et al. Everydaymmqa: A scalable semi-automatic framework for creating localized spoken and visual qa resources. *arXiv preprint arXiv:2510.06371*, 2025.

[2] K. Cheng et al. Culturellm: Incorporating cultural differences into large language models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024. URL: https://arxiv.org/abs/2402.10946.

[3] Research Team. Culturalpangea: A data-centric approach to culturally grounded mllms. *arXiv preprint arXiv:2508.07414*, 2025.

[4] Weizhe Lin and Bill Byrne. Retrieval augmented visual question answering with outside knowledge. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2022. URL: https://aclanthology.org/2022.emnlp-main.772/.

[5] M. Heakl et al. M2cqa: A culturally grounded multimodal benchmark. In *Findings of the Association for Computational Linguistics (ACL)*, 2026.

[6] Research Team. Cus-qa: Local knowledge oriented open-ended visual question answering. *Transactions of the Association for Computational Linguistics (TACL)*, 2024.